


260205 Bias Alignment



Financial Engineering Lab
Department of Industrial Engineering

Motivation

■ Investment Bias (Your ai, Not your view, 2025)



- LLM이 가진 편향을 정량화한 결과, LLM마다 특정 편향이 존재하며 주로 기술주(Tech) 및 대형주(Large-cap)에 대한 내재적 선호가 있다는 결론이 도출

Motivation

■ Research Questions

- 기존에 확인된 bias를 debiasing(완화) 할 수 있는가를 검증하고, 나아가 원하는 방향으로 bias를 컨트롤할 수 있는 방법론을 탐색

- Method 1:

- SFT / DPO 기반 튜닝: 특정 편향이 있는 LLM에 대해 반대 방향의 데이터(부정 데이터)를 생성하여 SFT 또는 DPO로 학습
- 어떻게 생성할것인지?

- Method 2:

- Subliminal Learning: Teacher 모델로 데이터 생성 → Student 모델 학습 시 Teacher의 내재적 view가 잠재적으로 반영되는 현상을 활용
- (ex: gpt-4.1 → deepseek-v3)

- Method 3:

- Controlled Tilting: 위 방법들로 debiasing이 가능하면,
- 원하는 방향으로 view를 컨트롤/tilting하는 단계로 확장

Motivation

- 크게 두 가지 storyline로 주제를 고안
 - 1. Bias Mitigation (편향 완화)
 - LLM의 내재적 편향을 여러가지 방법으로 debiasing / 원하는 방향 control
 - 하지만 학습 후 hallucination 등 generalization 성능이 망가지면 x
 - 2. 모델 응답의 다양성
 - 시장은 구조적으로 변화하며 과거의 성공 패턴이 미래에도 유지된다는 보장이 없기 때문에,
 - 금융시장의 구조적 변화 특성상, LLM이 균형 잡힌 다양한 의견을 생성할 수 있도록 만드는 방법

Bias Mitigation (PoC)


■ Experiment 1: Buy-biased Ticker Alignment

- Backbone:
 - Qwen-30B (Buy-biased Model)
- 목적:
 - 특정 티커에 대한 BUY 편향 교정
- 대상:
 - Buy rate 90% 이상인 티커들
- 학습 데이터:
 - 편향이 낮은 모델로 ticker에 대한 positive, negative 근거 생성 → DPO 학습
 - › Chosen: Sell 시나리오 (부정적 시나리오)
 - › Rejected: Buy 시나리오 (긍정적 시나리오)

```
◦ prompt: "Analyze TSN (Tyson Foods, Inc.) from a growth perspective."  
◦ chosen: "Tyson Foods' growth is losing momentum... margin pressure..."  
◦ rejected: "Tyson Foods demonstrates exceptional growth potential..."
```

Bias Mitigation (PoC)

Experiment 1: Buy-biased Ticker Alignment




- Bias index가 학습 초기에 지속적으로 낮아지다가 특정 구간 이후 다시 상승
- Buy/Sell ratio 전체적으로 Sell 의견이 증가하는 양상 관찰
- Memorization 문제: 학습 대상 티커와 비대상 티커를 분리 분석한 결과, 특정 티커에 대한 memorization이 아니라 전체적으로 의견이 Sell 방향으로 이동

Bias Mitigation (PoC)

Experiment 1: Buy-biased Ticker Alignment


DPO Debiasing: Bias Score Heatmap (Qwen3-30B)



- Sector / Size 별로 bias score를 시각화
- “전체적으로” bias가 완화되는 경향을 보임

Bias Mitigation (PoC)

■ Experiment 1: Buy-biased Ticker Alignment



- 학습 대상이 된 Ticker와 이외의 Ticker의 score를 분리하여 시각화
 - 특정 Ticker에 대해서 학습했기에 memorization의 가능성이 있음
 - 하지만 관계없이 전체적으로 sell 방향으로 이동하는 모습

Bias Mitigation (PoC)

■ Experiment 2: Sector Alignment

– 목적

- 편향이 강했던 Technology sector 주식을 대상

– 대상

- S&P 500 Technology 섹터 전체 58개 Tickers

– 학습 데이터:

- 편향이 낮은 모델로 ticker에 대한 positive, negative 근거 생성
- negative를 chosen, positive를 reject로 1,000 sample triplet 구성 후 DPO 학습
- Sell 방향으로 push

■ 긍정적 프롬프트 (예: macro perspective, LRCX):

```
Analyze LRCX (Lam Research Corporation) from a MACRO perspective.  
Be OPTIMISTIC. Sector: Technology | Market Cap: 73649646543 Focus  
on: favorable economic trends, supportive policy, growing demand  
drivers. Explain why macro conditions favor this company.
```


■ 부정적 프롬프트 (같은 티커, 같은 관점):

```
Analyze LRCX (Lam Research Corporation) from a MACRO perspective.  
Be PESSIMISTIC. Focus on: economic headwinds, regulatory risks,  
demand slowdown. Explain why macro conditions are unfavorable for  
this company.
```

Bias Mitigation (PoC)

Experiment 2: Sector Alignment

Tech (Sector DPO) Checkpoint Evaluation



- Bias index 지속 하락 양상
- Tech 섹터만 급격히 하락하는 것이 아니라 전체 섹터에 걸쳐 고르게 debiasing 됨
- 섹터 특정적 교정이 아닌 전반적 의견 교정 효과

Bias Mitigation (PoC)


■ Experiment 3: Size Alignment

- 목적
 - 편향이 강했던 시가총액 Q1 주식 대상
- 대상
 - S&P 500 Q1 107개 Tickers
- 학습 데이터:
 - 편향이 낮은 모델로 ticker에 대한 positive, negative 근거 생성
 - negative를 chosen, positive를 reject로 1,000 sample triplet 구성 후 DPO 학습
 - 매커니즘은 동일함 (Sell 방향으로 push)

Bias Mitigation (PoC)

Experiment 3: Size Alignment

Size (Q1 DPO) Checkpoint Evaluation



- Bias index 하락 양상 동일
- Q1 ticker만으로 학습했으나 Q1만 급격히 낮아지지 않고 Q2, Q3, Q4도 함께 교정
- 전반적인 학습이 이루어진 것으로 해석

Bias Mitigation (PoC)



- 추가 결과 예정

Bias Mitigation (PoC)

- 결론

- DPO 학습 시 KL divergence penalty가 원래 모델로부터의 급격한 shift를 방지
- Epoch을 늘렸을 때 파싱 실패 등 모델이 극도로 망가지는 현상은 관찰되지 않음
 - 다만 hallucination 등 Generalization에 대한 분석 필요
 - › 일반 벤치마크: MMLU (일반 지식 추론), TruthfulQA (Hallucination 측정 벤치마크)
 - › 금융 벤치마크: FPB (금융 감성 분류), FinBen/FLARE (금융 NLP 벤치마크)
- 특정 토크/섹터/사이즈에 대한 **memorization**은 발생하지 않음 → 전체적 의견 교정 효과

Bias Mitigation (PoC)

■ Discussion

– Bias Index 목표값에 대한 논의

- Question: Bias index가 어디까지 떨어지는 것이 이상적인가?
- Bias index를 단순히 낮추는 것이 목표가 아님
- 섹터/사이즈 간 격차 축소가 실질적 목표
- Ex: Tech 편향을 줄이고 싶다면, Tech와 나머지 섹터 사이의 bias 격차가 줄어들어야 이상적

– Neutral 목표에 대한 논의

- Bias Neutral(편향 중립)은 목표가 아님:
- 현실적 목표: bias가 존재하되, 원하는 방향으로 바꿀 수 있거나, 특정 부분의 과도한 편향을 눌러줄 수 있는 수준

– 실험 설계 개선 방향

- 현재 실험은 "타겟만 조정했더니 전체가 같이 움직이는" 상황
- 타겟은 낮추고 나머지는 올리는 방향으로 training data를 구성하여 차별적 교정 가능 여부 실험
- Output 레벨 질적 분석 필요: 수치적 bias index뿐 아니라 실제 생성된 응답의 질적 변화 확인 (예: earning call summary의 sentiment 변화 등)

Motivation

■ LLM의 획일화

- 정답이 없는 개방형 질문에서 답변이 비슷한 구조적 획일화 경향 존재




Figure 1: Responses to the query “Write a metaphor about time” clustered by applying PCA to reduce sentence embeddings to two dimensions. Each of the 25 models generates 50 responses using top- p sampling ($p = 0.9$) and temperature = 1.0. Despite the diversity of model families and sizes, the responses form just two primary clusters: a dominant cluster on the left centered on the metaphor “time is a river,” and a smaller cluster on the right revolving around variations of “time is a weaver.”

■ Problem

- 투자는 본질적으로 정답이 없는 거대한 개방형 문제
- 투자 데이터에서 Tech주/대형주 데이터가 과잉 → 공통적 선호 문제가 LLM 응답의 획일화와 연관될 가능성

[1] Jiang, L., Chai, Y., Li, M., Liu, M., Fok, R., Dziri, N., Tsvetkov, Y., Sap, M., Albalak, A., & Choi, Y. (2025). Artificial Hivemind: The Open-Ended Homogeneity of Language Models (and Beyond). In Advances in Neural Information Processing Systems (NeurIPS 2025). Best Paper Award.

PoC Results


■ PoC 실험

- Goal: 금융 scenario 생성 prompt를 주었을 때 모델별로 얼마나 diverse한 시나리오를 생성하는지?
- 방법: 시장 전반 시나리오 생성 프롬프트 → 응답 임베딩 → PCA 시각화
- 지표: 응답의 다양성을 측정하는 metrics
 - **Distinct-N**: 생성 텍스트에서 unique n-gram 수 / 전체 n-gram 수
 - **Cosine diversity**: (1 - cosine similarity),
 - **Centroid**와의 cosine distance 평균
 - **Pairwise semantic similarity**: NLI 모델이나 LLM-as-a-judge로 의미 중복 판단
- 또한 그것이 bias index와 관련이 있을지
- 그렇다면 어떻게 tuning (diversify)할 수 있을 것인지

[1] Shypula, A., Li, S., Zhang, B., Padmakumar, V., Yin, K., & Bastani, O. (2025). Evaluating the Diversity and Quality of LLM Generated Content. In Workshop on Deep Learning for Code (DL4C) at ICLR 2025.
[2] Shaib, C., Barrow, J., Sun, J., Siu, A.F., Wallace, B.C., & Nenkova, A. (2024). arXiv:2403.00553
[3] Guo, Y., Shang, G., & Clavel, C. (2024). arXiv:2412.10271

PoC Results

- Prompt: "Generate a possible future scenario for the U.S. stock market in 3-4 sentences."
 - 시장 전반에 대한 시나리오 생성에 대한 응답을 임베딩 → 차원축소 후 시각화



Prompt market_t1.0: "Generate a possible future scenario for the U.S. stock market in 3-4 sentences. ..."

PoC Results


- Prompt: "Generate a possible future scenario for the U.S. stock market in 3-4 sentences."
 - 시장 전반에 대한 시나리오 생성에 대한 응답을 임베딩 → 차원축소 후 시각화

Model	Bias Index	Cos Diversity	Cos-to-Centroid
gpt-oss-20b	37	0.2153	0.1148
Nemotron	291	0.1623	0.0836
Ministral-14B	90	0.1474	0.0751
Mistral-Small	372	0.1321	0.0691
Phi-4	477	0.1263	0.0650
Gemma3-27B	301	0.1242	0.0662
Qwen3-30B	137	0.0708	0.0360

- 모델별 다양성 지표
 - Cos Diversity = 1 - 평균 pairwise cosine similarity (클수록 시나리오가 다양)
 - Cos-to-Centroid = 각 시나리오에서 centroid까지 평균 cosine distance

PoC Results

- Pairwise cosine similarity heatmap



- 대부분의 모델이 cosine similarity 0.8 이상에 집중되어 응답 간 다양성이 낮으며,
- 특히 Qwen3-30B가 92.2%가 0.9–1.0 구간에 몰려 가장 획일적
- gpt-oss-20b가 0.7–0.8 구간에 66.1%로 상대적으로 가장 다양한 응답을 생성

PoC Results

■ Discussion

– 목적 (What)

- LLM이 투자 분석에서 생성하는 시나리오/의견의 다양성(diversity)을 정량화하고, 이를 향상시킬 수 있는 방법론을 제시하는 것

– 왜 필요한가 (Why)

- LLM이 투자 분석에서 생성하는 시나리오/의견의 다양성(diversity)을 정량화하고, 이를 향상시킬 수 있는 방법론을 제시하는 것
- 투자 의사결정에서 LLM을 활용할 때, bear case / bull case / alternative scenario 등 다양한 관점을 생성할 수 있어야 비로소 유용해짐. 획일적 응답은 "편향된 하나의 의견"에 불과
- Bias는 "방향의 편향"이고, homogeneity는 "다양성의 부재"

PoC Results

■ Discussion

– 방법 (How)

- **DivPO (Lanchantin et al., 2025):**

- › DPO에서 chosen을 "높은 quality + 높은 rarity", rejected를 "낮은 quality + 높은 commonness"로 구성해 diversity를 학습 단계에서 직접 최적화

- **Deviation-aware DPO (Chung et al., COLM 2025):**

- › 같은 프롬프트의 다른 응답들과 얼마나 다른지(deviation)를 DPO/ORPO 목적함수에 반영하여 diverse하면서도 high-quality인 응답을 유도

- **Soft Preference Learning (ICLR'25):**

- › RLHF/DPO의 KL divergence regularizer가 다수 의견에 과적합하여 diversity를 희생시키는 원인임을 밝히고, KL penalty의 entropy와 cross-entropy 항을 분리(decouple)하여 generation diversity를 세밀하게 제어할 수 있는 Soft Preference Learning을 제안



Thank you for listening!